T.C.

TRAKYA ÜNİVERSİTESİ

FEN BİLİMLERİ ENSTİTÜSÜ

MELANOM TESPİTİNDE KULLANILAN DERİN ÖĞRENME YÖNTEMLERİ

MOUSTAFA MOUSTAFA

YÜKSEK LİSANS SEMİNERİ

BİLGİSAYAR MÜHENDİSLİĞİ ANABİLİM DALI

Tez Danışmanı: Doç. Dr. Emir ÖZTÜRK

EDİRNE-2026

Yüksek Lisans Semineri

MELANOM TESPİTİNDE KULLANILAN DERİN ÖĞRENME YÖNTEMLERİ

T.Ü. Fen Bilimleri Enstitüsü

Bilgisayar Mühendisliği Anabilim Dalı

ÖZET

Bu çalışmada, cilt kanseri vakaları arasında en yüksek ölüm riskini barındıran melanomun erken teşhisinde derin öğrenme yöntemlerinin ve bilgisayar destekli tanı (CAD) sistemlerinin rolü incelenmiştir. Çalışmanın amacı, literatürde açık erişime sunulan HAM10000, ISIC, PH2 ve DermIS gibi veri setleri üzerinde, farklı derin öğrenme algoritmalarının başarı oranlarını karşılaştırmalı olarak sunmaktır. Yöntem olarak; CNN, ResNet, VGG, EfficientNet, U-Net, Inception, Xception, MobileNet ve NASNet gibi güncel mimarilerin yapısal özellikleri ve literatürdeki uygulamaları detaylandırılmıştır. İncelemeler sonucunda, derin öğrenme modellerini sıfırdan eğitmek yerine Transfer Öğrenme (Transfer Learning) yaklaşımının teşhis başarısını ciddi oranda artırdığı görülmüştür. Ayrıca, U-Net gibi ağlarla özellik çıkarımı yapıp Destek Vektör Makineleri (SVM) ile sınıflandırma yapan melez (hybrid) modellerin standart ağların ötesine geçtiği saptanmıştır. Çalışmadan elde edilen en belirgin sonuç, farklı modellerin tahmin yeteneklerini belirli ağırlıklarla birleştiren Karar Füzyonu (Decision Fusion) mimarilerinin %95 gibi yüksek doğruluk oranlarına ulaşarak literatürde en başarılı sonuçları verdiğidir.

Yıl : 2026

Sayfa Sayısı : 35

Anahtar Kelimeler : Bilgisayar Destekli Tanı, Derin Öğrenme, Evrişimsel Sinir Ağları, Karar Füzyonu, Melanom Tespiti, Transfer Öğrenme

Master's Thesis

DEEP LEARNING METHODS USED IN MELANOMA DETECTION

Trakya University Institute of Natural and Applied Sciences

Department of Computer Engineering

ABSTRACT

In this study, the role of deep learning methods and computer-aided diagnosis (CAD) systems in the early detection of melanoma, which carries the highest mortality risk among skin cancer cases, is investigated. The aim of the study is to present a comparative analysis of the success rates of different deep learning algorithms on open-access datasets such as HAM10000, ISIC, PH2, and DermIS in the literature. As a methodology, the structural characteristics and literature applications of state-of-the-art architectures such as CNN, ResNet, VGG, EfficientNet, U-Net, Inception, Xception, MobileNet, and NASNet are detailed. The reviews revealed that utilizing the Transfer Learning approach rather than training deep learning models from scratch significantly increases diagnostic success. Furthermore, it was determined that hybrid models, which perform feature extraction with networks like U-Net and classification with Support Vector Machines (SVM), surpass standard networks. The most prominent result obtained from the study is that Decision Fusion architectures, which combine the prediction capabilities of different models with specific weights, yield the most successful results in the literature by reaching high accuracy rates of up to 95%.

Year 2026

Number of Pages : 35

Keywords : Computer-Aided Diagnosis, Convolutional Neural Networks, Decision Fusion, Deep Learning, Melanoma Detection, Transfer Learning

İÇİNDEKİLER

ÖZET ii

ABSTRACT iii

İÇİNDEKİLER iv

SİMGELER VE KISALTMALAR DİZİNİ vi

ŞEKİLLER DİZİNİ vii

ÇİZELGELER DİZİNİ viii

BÖLÜM 1 1

GİRİŞ 1

BÖLÜM 2 3

MATERYAL VE YÖNTEM 3

2.1. Veri Setleri 3

2.1.1 HAM 10,000 3

2.1.2 ISIC 2017, 2018, 2019 3

2.1.3 ISBI 2016 4

2.1.4 PH2 4

2.1.5 DermIS (Dermatology Information System) 5

2.2. Derin Öğrenme Algoritmaları 5

2.2.1 Evrişimsel Sinir Ağları (Convolutional Neural Networks – CNN) 5

2.2.2 Artık Sinir Ağları (Residual Neural Networks – ResNet) 6

2.2.3 VGG Mimarileri (VGG – 16 ve VGG – 19) 7

2.2.4 EfficientNet 8

2.2.5 U-Net 9
2.2.6 Inception Mimarileri (GoogLeNet ve Inception-V3) 10
2.2.7 Xception 11
2.2.8 MobileNet 12
2.2.9 NasNet-Large 13
BÖLÜM 3 15
LİTERATÜR TARAMASI VE BULGULAR 15
3.1. Literatür Bulgularının Değerlendirilmesi 19
BÖLÜM 4 21
SONUÇ 21
KAYNAKLAR 22
ÖZGEÇMİŞ 27

SİMGELER VE KISALTMALAR DİZİNİ

CAD:	Bilgisayar destekli tanı (Computer Aided Diagnosis)
CNN:	Evrişimsel Sinir Ağları (Convolutional Neural Networks)
ResNet:	Artık Sinir Ağları (Residual Neural Networks**)**
SVM:	Destek Vektör Makineleri (Support Vector Machines)
RF:	Rastgele Orman (Random Forrest)

ŞEKİLLER DİZİNİ

Şekil 2.1. Tipik bir evrişimsel sinir ağı (CNN) mimarisi (Phung & Rhee, 2019) 6

Şekil 2.2. ResNet-50 mimarisinin yapısal şeması (Demirtaş vd., 2025) 7

Şekil 2.3. VGG-16 mimarisinin katman yapısı (Pal vd., 2020) 8

Şekil 2.4. EfficientNet-B0 mimarisinin temel yapı blokları ve katman detayları (Zhou vd., 2023) 9

Şekil 2.5. U-Net mimarisinin simetrik (daralan ve genişleyen) yapısı (Guo vd., 2020) 10

Şekil 2.6. GoogLeNet mimarisi (Chen vd., 2020) 11

Şekil 2.7. Xception mimarisinin detaylı yapısı ve derinliğine ayrılabilir evrişim (sconv) katmanları (Srinivasan vd., 2021) 12

Şekil 2.8. MobileNet mimarisi ve derinliğine/noktasal (DWC/PWC) evrişim katmanları (Neris vd., 2022) 13

Şekil 2.9. NASNet-Large mimarisinin yapay zekâ tarafından tasarlanan karmaşık iç hücre yapısı (El-Khatib vd., 2020) 14

ÇİZELGELER DİZİNİ

Çizelge 3.1. İncelenen literatür çalışmalarının karşılaştırmalı özeti 15

BÖLÜM 1

GİRİŞ

Cilt kanserleri en çok görülen kanser türüdür ve tüm kanser vakalarının yaklaşık %50'sini oluşturmaktadır (Türk Kanser Derneği, 2026). Farklı cilt kanserlerinin farklı belirtileri bulunmakla birlikte, cilt yüzeyindeki gözle görülür bulgular kişiden kişiye değişiklik gösterebilir.

En tehlikeli cilt kanseri olarak bilinen kötü huylu cilt kanseri (melanom), erken teşhis edilmediğinde ölümcül olabilmektedir. Diğer cilt kanseri türlerine göre daha nadir görülmekle birlikte, erken evrede saptandığı takdirde tedavisi mümkündür (Türk Kanser Derneği, 2026). Çeşitli deri kanserleri arasında, kötü huylu cilt kanserinin beyaz ırkta görülme sıklığı son 30 yılda dört katına çıkmıştır (Jones vd., 2019).

Makine öğrenmesi ve derin öğrenme, son yıllarda sağlık sektöründe de yaygın olarak kullanılmaya başlanan ve hızla gelişen iki alandır. Her ikisi de tahminlerin veya kararların doğruluğunu ve verimliliğini artırmak amacıyla verilerden öğrenen algoritmaların kullanımını içerir. Makine öğrenmesi verilerden öğrenmek için tipik olarak istatistiksel yöntemler kullanırken, derin öğrenme büyük veri setlerinden öğrenmek için yapay sinir ağlarını kullanır (Sharifani & Amini, 2023).

Çeşitli meta-analizler, dermoskopinin çıplak gözle yapılan muayeneye kıyasla tanısal doğruluğu önemli ölçüde artırdığını göstermiştir. Bununla birlikte, farklı dermoskopik algoritmalar konusunda resmi eğitim almış dermatologların ve tıp doktorlarının melanom tespitindeki ortalama duyarlılıklarının çoğunlukla %80'in altında olduğu görülmüştür. Son yıllarda, melanom taramasında yüksek ve geniş çapta tekrarlanabilir bir tanısal doğruluk sağlamak amacıyla, hekimlere yardımcı olabilecek çeşitli otomatik bilgisayar destekli görüntü analizi stratejileri araştırılmıştır (Haenssle vd., 2018). Bu nedenle cilt kanseri tanıma için otomatik ve güvenilir bir bilgisayar destekli

tanı (Computer Aided Diagnosis, CAD) sistemi, dermatologlara kararlarını desteklemek ve yardımcı olmak için ikinci bir görüş sağlayan önemli bir değerlendirme aracı olarak ortaya çıkmıştır (Jones vd., 2019). Literatürde bir dönüm noktası kabul edilen bir çalışmada, 1,2 milyondan fazla yüksek çözünürlüklü görüntü 60 milyon parametreli derin bir CNN mimarisiyle eğitilmiş ve %15,3 gibi rekor bir hata oranıyla sınıflandırılarak önceki geleneksel yöntemlere karşı ezici bir üstünlük sağlanmıştır (Krizhevsky vd., 2017). Bu olağanüstü başarı, bilgisayarlı görü alanında derin öğrenmenin standart hale gelmesine öncülük etmiştir.

Bu çalışmada, bilgisayar destekli tanı sistemlerinin geliştirilmesinde kullanılan görüntü işleme teknikleri ve farklı derin öğrenme mimarilerinin literatürdeki yeri incelenmiştir. Çalışmanın amacı; literatürde açık erişime sunulan çeşitli cilt kanseri veri setleri üzerinde, farklı algoritmaların başarı oranlarını, duyarlılıklarını ve genellenebilirlik kapasitelerini karşılaştırmalı olarak sunmaktır.

BÖLÜM 2

MATERYAL VE YÖNTEM

2.1. Veri Setleri

2.1.1 HAM 10,000

HAM10000 veri seti, cilt lezyonlarının görüntülerinden oluşan bir koleksiyondur, özellikle melanom ve diğer cilt kanseri türlerine odaklanmaktadır. Dermatoloji, tıbbi görüntüleme ve makine öğreniminde, görüntü sınıflandırma, segmentasyon ve tanı gibi görevler için yaygın olarak kullanılmakta, farklı hastalardan alınmış 10,015 deri lezyonu dermoskopi görüntüsü içermektedir. Bu görüntüler, dermatologların cilt lezyonlarını ayrıntılı olarak incelemek için kullandığı taşınabilir bir cihaz olan dermatoskop kullanılarak kontrollü koşullar altında çekilmiştir. Veri setindeki görüntüler farklı çözünürlük ve kalitededir, bu da gerçek dünya klinik görüntülerinin çeşitliliğini yansıtmaktadır. Her görüntü, melonomun varlığı veya yokluğu da dahil olmak üzere tanı ile ilgili bilgilerle etiketlenmiştir. Bu veri seti, iyi huylu ve kötü huylu cilt lezyonlarını ayırt etmek için görüntü sınıflandırma gibi çeşitli görevlerde kullanılır (Naseri & Safaei, 2025).

2.1.2 ISIC 2018, 2019

ISIC veri seti (Uluslararası Cilt Görüntüleme İş birliği veri seti - International Skin Imaging Collaboration dataset) dermatoloji alanında araştırmalar için kullanılan cilt görüntülerinden oluşan bir koleksiyondur, özellikle otomatik cilt kanseri tespit sistemlerinin geliştirilmesinde kullanılır. Lezyon türü (örneğin melanom), hasta yaşı ve lezyon konumu gibi ilgili meta verilerle birlikte yüksek çözünürlüklü deri lezyonları görüntüleri içerir. Dermoskopi ve klinik fotoğrafçılık dahil olmak üzere çeşitli görüntüleme modları kullanılarak elde edilen görüntülerden oluşur. Cilt lezyonlarının tanısı ve sınıflandırılmasında makine öğrenimi ve derin öğrenme algoritmalarının performansını değerlendirmek için bir kıyaslama veri seti olarak kullanılır (Naseri & Safaei, 2025).

2.1.3 ISBI 2016

ISBI 2016 (International Symposium on Biomedical Imaging) veri seti, Uluslararası Cilt Görüntüleme İş birliği (ISIC) tarafından bilgisayar destekli otomatik melanom teşhisi sistemlerinin geliştirilmesini teşvik etmek amacıyla araştırmacılara sunulmuş temel bir veri setidir. Bu veri seti, makine öğrenmesi ve derin öğrenme modellerini eğitmek ve test etmek amacıyla 900 eğitim (training) ve 379 test olmak üzere toplam 1279 yüksek çözünürlüklü dermoskopik görüntü içermektedir. İçerisindeki lezyonlar temel olarak iyi huylu (benign) ve kötü huylu (melanom) olmak üzere iki sınıfa ayrılmıştır. ISBI 2016 veri seti, araştırmacıları üç ana görevde test etmek üzere kurgulanmıştır: lezyon bölütleme (segmentasyon), dermoskopik özellik çıkarımı ve hastalık sınıflandırması. Özellikle birinci görev olan lezyon bölütleme için uzman dermatologlar tarafından piksel düzeyinde hazırlanmış ikili maskeler (binary masks) içermesi, bu veri setini U-Net gibi segmentasyon algoritmalarının eğitilmesinde ve performanslarının kıyaslanmasında (benchmark) literatürde bir standart haline getirmiştir (Gutman vd., 2016).

2.1.4 PH2

PH2 veri seti, bilgisayar destekli tanı sistemlerinin geliştirilmesi ve algoritmaların adil bir şekilde kıyaslanabilmesi (benchmarking) amacıyla Porto Üniversitesi, Técnico Lisboa ve Pedro Hispano Hastanesi işbirliğiyle oluşturulmuş bir dermoskopik görüntü veri tabanıdır. Veri seti, 768x560 piksel çözünürlüğünde ve 20x büyütme ile standart koşullar altında elde edilmiş toplam 200 adet yüksek çözünürlüklü görüntü içermektedir. Bu görüntülerin 80'i normal nevüs (iyi huylu), 80'i atipik nevüs ve 40'ı melanom (kötü huylu) vakalarından oluşmaktadır. PH2 veri setini literatürde değerli kılan en önemli sebep, içerdiği tüm görüntülerin uzman dermatologlar tarafından detaylıca incelenmiş ve etiketlenmiş olmasıdır. Veri seti, bilgisayarlı görü algoritmalarını test etmek için her bir lezyonun piksel bazlı manuel bölütleme (segmentasyon) maskesini sunmasının yanı sıra; asimetri, renk dağılımı, pigment ağı ve mavi-beyaz örtü (blue-whitish veil) gibi klinik dermoskopik kriterleri de araştırmacıların kullanımına sunmuştur (Mendonca vd., 2013).

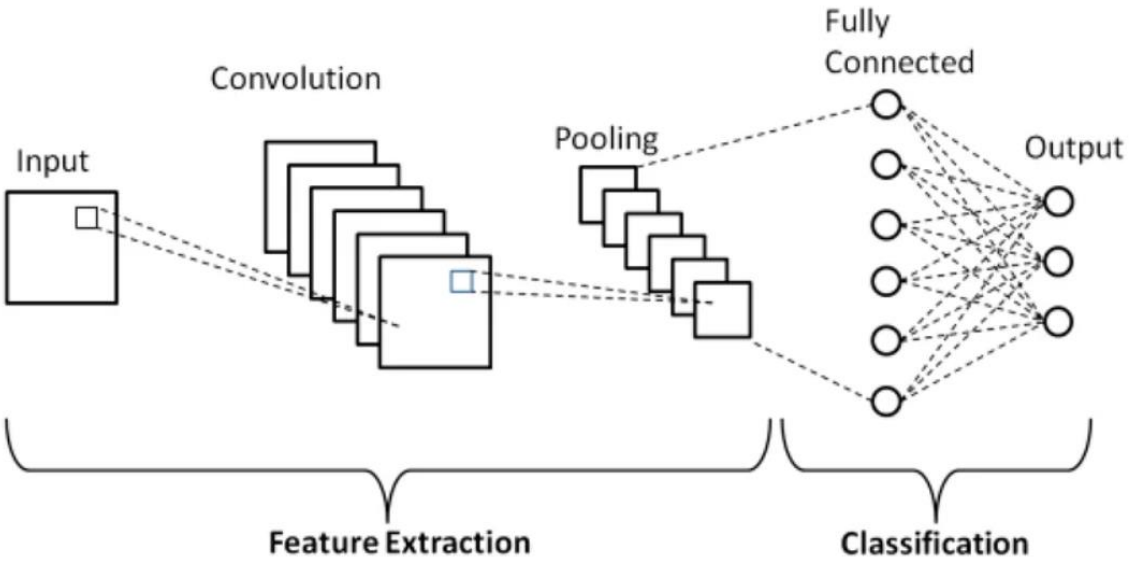
2.1.5 DermIS (Dermatology Information System)

DermIS, internet üzerindeki en kapsamlı dermatoloji bilgi kaynaklarından ve klinik atlaslardan biri olarak kabul edilmektedir. Başlangıçta bilgisayarlı görü algoritmaları için bir veri seti olarak değil, tıp profesyonelleri için bir eğitim ve referans platformu olarak (dermis.net) kurulmuştur. Ancak içerdiği binlerce doğrulanmış yüksek çözünürlüklü lezyon fotoğrafı, detaylı klinik açıklamalar ve ayırıcı tanılar sayesinde makine öğrenmesi araştırmacılarının da büyük ilgisini çekmiştir. Özellikle nadir görülen cilt hastalıklarını barındırması ve derin öğrenme modellerinin eğitiminde veri çeşitliliğini artırması nedeniyle, literatürdeki melez (hybrid) sınıflandırma çalışmalarında destekleyici veri seti olarak sıklıkla kullanılmaktadır (*DermIS*, 2026)

2.2. Derin Öğrenme Algoritmaları

2.2.1 Evrişimsel Sinir Ağları (Convolutional Neural Networks – CNN)

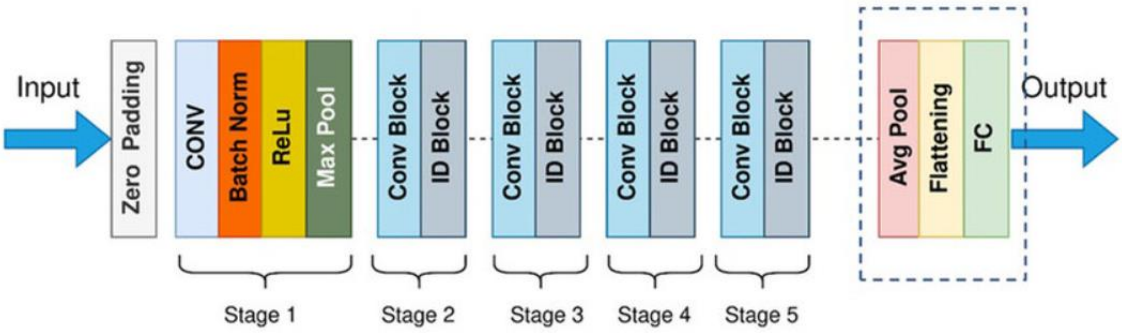
Evrişimsel Sinir Ağları (CNN), çok boyutlu verileri işlemek için tasarlanmış ve temel olarak evrişim, havuzlama (pooling) ve tam bağlı (fully-connected) katmanlardan oluşan derin öğrenme mimarileridir (Şekil 2.1). Evrişim katmanı birden fazla farklı evrişim çekirdeğinden oluşur. Bu çekirdekler görüntü üzerinde farklı özelliklerin çıkarılması için kullanılırlar. Sonrasında aktivasyon fonksiyonu kullanılarak modele doğrusal olmayan bir yapı (non-lineerite) kazandırılır. En bilinen aktivasyon fonksiyonlarına ise sigmoid, tanh (LeCun vd., 2012) ve RELU (Nair & Hinton, 2010) örnek verilebilir. Aktivasyon fonksiyonu olarak RELU kullanılması yapay sinir ağlarının daha hızlı öğrenmesini ve daha yüksek sınıflandırma başarısı elde etmesini sağlamaktadır. Ağın işlem yükünü hafifletmek amacıyla kullanılan havuzlama (pooling) katmanları, girdi verilerinin boyutunu küçülterek hesaplama maliyetini düşürür ve aynı zamanda modelin ezberlemesini (aşırı öğrenme - overfitting) engellemeye yardımcı olur. Bu mimarilerde en çok başvurulan yaklaşımlar ortalama havuzlama (average pooling) ve maksimum havuzlama (max pooling) işlemleridir. Sınıflandırma işlemleri ise genellikle ağın sonundaki tam bağlı katmanlar ve Softmax gibi fonksiyonlar aracılığıyla gerçekleştirilir (Öztürk & Mesut, 2020).



Şekil 2.1. Tipik bir evrişimsel sinir ağı (CNN) mimarisi (Phung & Rhee, 2019)

2.2.2 Artık Sinir Ağları (Residual Neural Networks – ResNet)

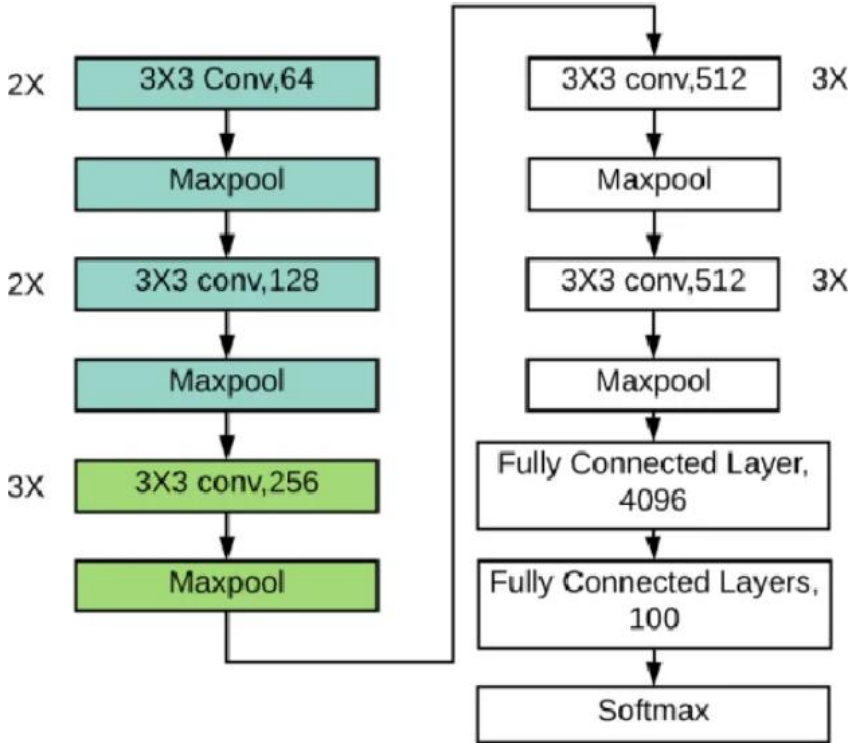
Artık Sinir Ağları (ResNet), geleneksel evrişimli sinir ağlarında katman sayısı arttıkça modelin eğitimini zorlaştıran ve başarımını düşüren kaybolan gradyan (vanishing gradient) problemini (Bengio vd., 1994) çözmek amacıyla geliştirilmiş bir mimaridir. Bu mimaride, ağ içindeki bilginin kaybolmasını önlemek için bazı katmanları atlayarak doğrudan bir sonraki katmanlara veri aktaran artık bloklar (residual blocks) yer almaktadır (He vd., 2015). ResNet'in literatürde en yaygın kullanılan versiyonlarından biri olan ResNet50; 49 evrişim katmanı ve 1 tam bağlı katman olmak üzere toplam 50 katmanlı derin bir yapıya sahiptir (Şekil 2.2). ResNet mimarisi, sahip olduğu bu atlama bağlantıları sayesinde çok daha derin ağların başarıyla eğitilmesine olanak tanımakta ve karmaşık görüntü sınıflandırma görevlerinde yüksek doğruluk (accuracy) oranları sunmaktadır. Literatürde ResNet-50'nin yanı sıra, aynı 'artık blok' (residual block) mantığını koruyarak ağ derinliğinin sırasıyla 101 ve 152 katmana çıkarıldığı ResNet-101 ve ResNet-152 versiyonları da sıklıkla kullanılmaktadır. Katman sayısı (derinlik) arttıkça modelin hesaplama maliyeti yükselse de karmaşık cilt lezyonlarından çok daha soyut ve ince detaylı özelliklerin (features) çıkarılması sağlanmaktadır.



Şekil 2.2. ResNet-50 mimarisinin yapısal şeması (Demirtaş vd., 2025)

2.2.3 VGG Mimarileri (VGG – 16 ve VGG – 19)

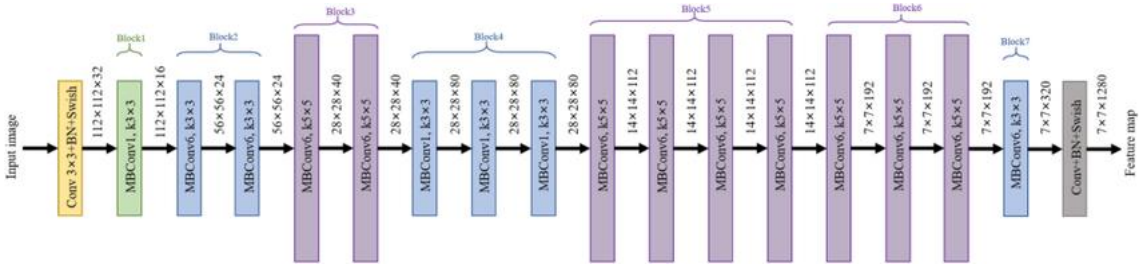
VGG16, Oxford Üniversitesi bünyesindeki Visual Geometry Group tarafından geliştirilen ve evrişimli sinir ağlarında (CNN) ağ derinliğinin modelin başarısı üzerindeki etkisini kanıtlayan temel mimarilerden biridir (Simonyan & Zisserman, 2015). VGG16 13 kıvrımlı katman (convolutional layer) ve 3 tam bağlantılı katman (fully connected layer) dahil olmak üzere 16 katmandan oluşur. Evrişimli katmanlar, giriş görüntülerinden öznitelikleri çıkarmak için kullanılırken, tam bağlantılı katmanlar sınıflandırma için kullanılır. İlk blok 64 filtreye sahipken, kalan bloklar sırasıyla 128, 256, 512 ve 512 filtreye sahiptir (Şekil 2.3). VGG16 mimarisinin en önemli özelliklerinden biri, evrişimli katmanlarda küçük 3x3 filtreler kullanmasıdır, bu da onun uzamsal bilgileri daha büyük filtrelerden daha etkili bir şekilde yakalamasına olanak tanır. Aynı araştırma ekibi tarafından literatüre sunulan bir diğer versiyon olan VGG-19 ise, VGG-16 ile tamamen aynı temel mimari yaklaşımı paylaşmakla birlikte, 3 adet fazladan evrişim katmanı barındırarak toplam 19 ağırlık katmanından oluşmaktadır (Gezer vd., 2024).



Şekil 2.3. VGG-16 mimarisinin katman yapısı (Pal vd., 2020)

2.2.4 EfficientNet

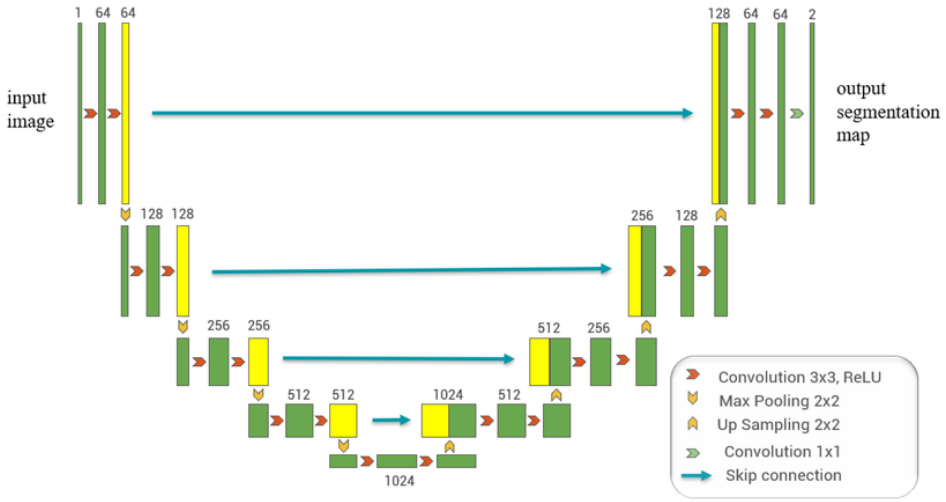
Literatürde evrişimsel sinir ağlarının (CNN) performansını yükseltmek için genellikle ağın genişliği, derinliği veya girdi çözünürlüğü gibi parametrelerden yalnızca biri artırılır. EfficientNet mimarisi ise bu klasik yaklaşımın dışına çıkarak "bileşik ölçeklendirme" (compound scaling) yöntemini ortaya koymuştur. Bu yönteme göre ağın boyutları rastgele veya tek tek değil, ortak bir matematiksel katsayı üzerinden birbirleriyle orantılı olarak büyütülür. Ailenin temelini oluşturan EfficientNet-B0 ağı hem yüksek doğruluk hem de düşük hesaplama maliyeti (FLOPS) hedeflenerek sinirsel mimari arama (neural architecture search) algoritmalarıyla tasarlanmıştır (Şekil 2.4). Kurulan bu yapısal denge sayesinde EfficientNet modelleri, ResNet veya VGG gibi geleneksel mimarilerin aksine çok daha az parametre barındırmasına rağmen literatürde daha yüksek doğruluk (accuracy) oranları ve işlem hızları sunmaktadır (Tan & Le, 2019).



Şekil 2.4. EfficientNet-B0 mimarisinin temel yapı blokları ve katman detayları (Zhou vd., 2023)

2.2.5 U-Net

Cilt kanseri tespiti problemlerinde, sadece lezyonun türünü sınıflandırmak yeterli olmamakta, aynı zamanda lezyonun sınırlarının sağlıklı deriden hassas bir şekilde ayrıştırılması (bölütleme - segmentasyon) son derece önem taşımaktadır. Bu nedenle biyomedikal görüntü segmentasyonu için özel olarak geliştirilmiş olan U-Net mimarisi literatürde standart bir yaklaşım haline gelmiştir. U-Net, ismini aldığı "U" harfi şeklindeki simetrik yapısı sayesinde klasik evrişimsel sinir ağlarından ayrılır (Şekil 2.5). Mimari temel olarak iki yoldan oluşur: Görüntüden bağlamsal özelliklerin (context) çıkarıldığı daralan yol (contracting path) ve bu özelliklerin yüksek çözünürlüklü piksellerle eşleştirilerek hedefin tam konumunun belirlendiği genişleyen yol (expansive path). Klasik ağlar görüntünün tamamı için tek bir sınıflandırma çıktısı üretirken, U-Net mimarisi görüntüdeki her bir pikselin hangi sınıfa (örneğin sağlıklı deri veya melanom) ait olduğunu piksel bazında tahmin ederek yüksek çözünürlüklü bir maske (binary mask) oluşturur. Bu özelliği sayesinde U-Net, az sayıda eğitim verisiyle bile cilt lezyonlarının sınırlarını başarılı bir şekilde tespit edebilmektedir (Ronneberger vd., 2015).

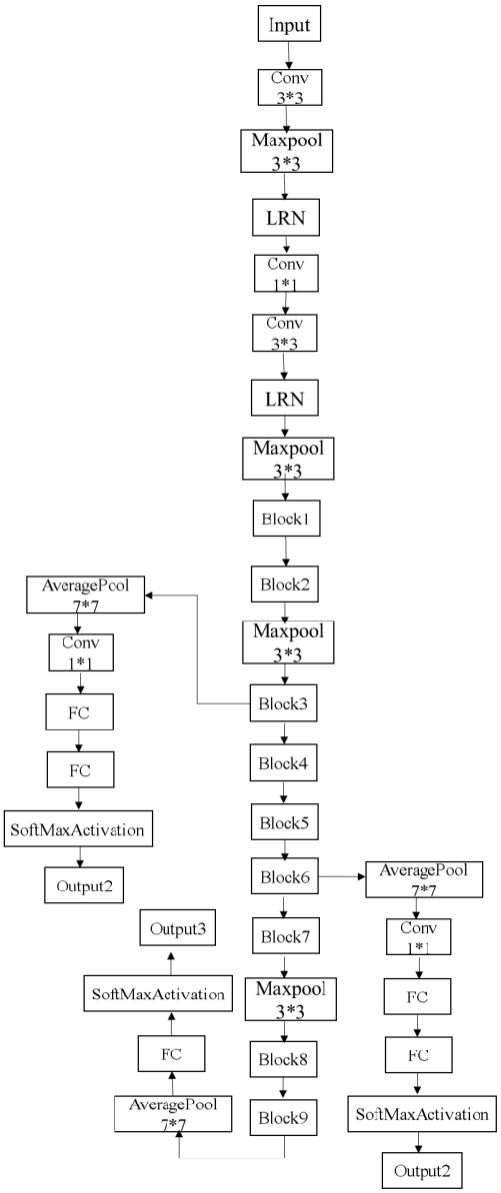


Şekil 2.5. U-Net mimarisinin simetrik (daralan ve genişleyen) yapısı (Guo vd., 2020)

2.2.6 Inception Mimarileri (GoogLeNet ve Inception-V3)

Inception mimarisi (literatürdeki ilk sürümüyle GoogLeNet olarak da bilinir), Christian Szegedy ve ekibi tarafından geliştirilmiş ve evrişimsel sinir ağlarında (CNN) ağ kaynaklarının kullanım verimliliğini devrim niteliğinde artıran bir yaklaşımdır. Geleneksel mimarilerde ağın her katmanında tek bir filtre boyutu (örneğin sadece 3x3 veya sadece 5x5) seçilmesi gerekirken, Inception mimarisi "Inception Modülü" adı verilen özel bloklar sayesinde aynı katman içerisinde farklı boyutlardaki (1x1, 3x3, 5x5) filtreleri paralel olarak uygular ve elde edilen sonuçları birleştirir (Şekil 2.6). Bu paralel yapı sayesinde ağ, görüntüdeki hem küçük ve ince detayları hem de büyük ve genel yapıları (çok ölçekli özellikler) aynı anda algılayabilmektedir. Artan parametre sayısını ve donanım maliyetini kontrol altında tutmak için ise bu mimari içerisinde boyut azaltıcı 1x1'lik evrişimler (dimensionality reduction) kullanılmıştır. 2014 yılındaki ImageNet yarışmasında birinci olan bu mimari, cilt lezyonlarının farklı boyutlarda, şekillerde ve dokularda olabilmesi nedeniyle, dermoskopik görüntülerden çok ölçekli özellik çıkarımı (multi-scale feature extraction) yapmak için bilgisayar destekli teşhis sistemlerinde yaygın olarak kullanılmaktadır. Orijinal mimarinin zaman içinde optimize edilmesiyle ortaya çıkan Inception-V3 versiyonu ise, büyük evrişim filtrelerini daha küçük asimetrik filtrelere bölerek (factorized convolutions) hesaplama maliyetini daha da düşürmüş ve

cilt kanseri teşhisi gibi yüksek çözünürlüklü tıbbi görüntü analizlerinde doğruluk oranını artırmıştır (Szegedy vd., 2014).

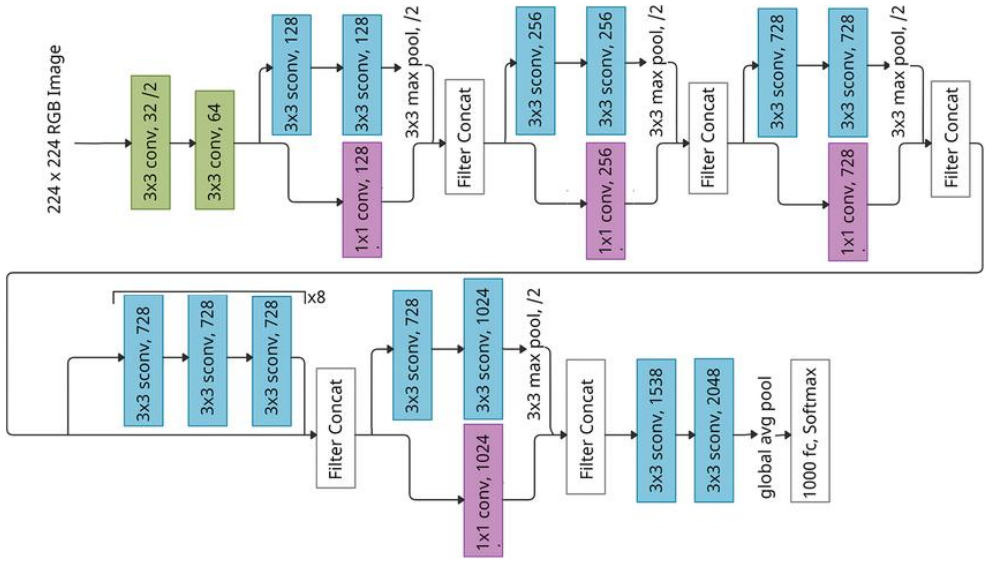


Şekil 2.6. GoogLeNet mimarisi (Chen vd., 2020)

2.2.7 Xception

Xception (Extreme Inception), François Chollet tarafından Inception mimarisi (Szegedy vd., 2014) temel alınarak geliştirilmiş derin bir evrişimsel sinir ağı (CNN) mimarisidir. Mimari, temel olarak hesaplama karmaşıklığını azaltırken yüksek performansı korumayı amaçlayan "derinliğine ayrılabilir evrişimler" (depthwise

separable convolutions) fikrine dayanmaktadır. Geleneksel evrişimsel sinir ağı mimarilerinde katmanlar, kullanılan filtreyi (kernel) tüm girdi hacmine aynı zamanda uygulayarak çok yüksek parametre sayısına, dolayısıyla artan hesaplama maliyetine neden olur. Xception mimarisi ise bu standart evrişim işlemini iki bağımsız adıma bölmektedir: derinliğine evrişimler (depthwise convolutions) ve noktasal evrişimler (pointwise convolutions)(Şekil 2.7). Bu yenilikçi yaklaşım sayesinde Xception, kendinden önceki mimarilere kıyasla işlem yükünü büyük ölçüde hafifletirken, görüntü sınıflandırma problemlerinde literatürdeki en başarılı (state-of-the-art) sonuçlardan bazılarına ulaşmayı başarmış ve melez (hybrid) cilt kanseri teşhisi sistemlerinde güçlü bir özellik çıkarıcı (feature extractor) olarak kendine yer bulmuştur (Chollet, 2016).



Şekil 2.7. Xception mimarisinin detaylı yapısı ve derinliğine ayrılabilir evrişim (sconv) katmanları (Srinivasan vd., 2021)

2.2.8 MobileNet

MobileNet, Google araştırmacıları tarafından özellikle mobil cihazlar, gömülü sistemler ve düşük donanım gücüne sahip uç cihazlar (edge devices) için geliştirilmiş hafif bir evrişimsel sinir ağı (CNN) mimarisidir. Geleneksel evrişim işlemlerinin yarattığı yüksek hesaplama maliyetini ve bellek ihtiyacını azaltmak amacıyla, standart evrişim işlemini iki aşamaya bölen "derinliğine ayrılabilir evrişimler" (depthwise separable convolutions) tekniğini kullanır (Şekil 2.8). Bu sayede modelin parametre sayısı ve matematiksel işlem yükü (bölümleme maliyeti) büyük oranda azalırken, sınıflandırma doğruluğunda yalnızca tolere edilebilir, çok küçük bir düşüş yaşanır. Cilt kanseri teşhisi

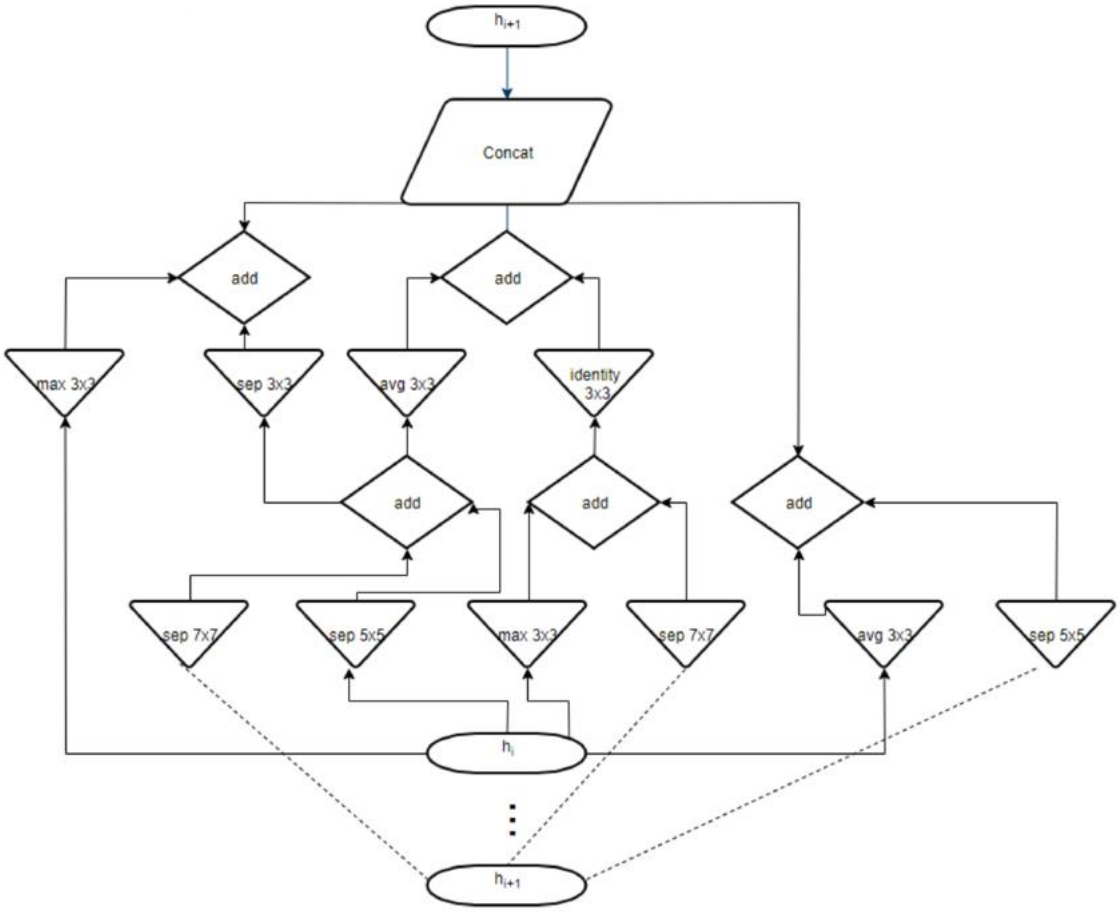
alanında, hastaların veya uzmanların akıllı telefon kameralarını kullanarak gerçek zamanlı ve hızlı lezyon analizi yapabilmesini amaçlayan mobil dermoskopi uygulamalarının tasarlanmasında en çok tercih edilen mimarilerden biridir (Howard vd., 2017).



Şekil 2.8. MobileNet mimarisi ve derinliğine/noktasal (DWC/PWC) evrişim katmanları (Neris vd., 2022)

2.2.9 NasNet-Large

NasNet (Neural Architecture Search Network), derin öğrenme literatüründe geleneksel mimarilerden çok daha farklı ve otonom bir yaklaşıma sahiptir. İnsan mühendisler tarafından deneme-yanılma yoluyla tasarlanan standart ağların aksine NASNet mimarisi, pekiştirmeli öğrenme (reinforcement learning) kullanılarak başka bir sinir ağı (Controller) tarafından otomatik olarak keşfedilmiştir. Google Brain ekibi, ağın temel yapı taşlarını (Normal Cell ve Reduction Cell) önce küçük bir veri setinde aratmış, ardından keşfedilen bu ideal yapı taşlarını uç uca ekleyip büyüterek devasa ImageNet veri setine uygulamıştır. Bu ölçeklendirme işlemi sonucunda ortaya çıkan en kapsamlı, en derin ve parametre kapasitesi en yüksek versiyon NASNet-Large olarak adlandırılmıştır (Şekil 2.9). İnsan sezgisinin ötesindeki bu karmaşık matematiksel dizilimi sayesinde NASNet-Large, cilt kanseri teşhisi gibi en ufak piksel dokusunun bile hayati önem taşıdığı tıbbi teşhis sistemlerinde inanılmaz yüksek doğruluk oranlarına ulaşmış ve "Karar Füzyonu" (Decision Fusion) modellerinin vazgeçilmez bir parçası haline gelmiştir (Zoph vd., 2018).



Şekil 2.9. NASNet-Large mimarisinin yapay zekâ tarafından tasarlanan karmaşık iç hücre yapısı (El-Khatib vd., 2020)

BÖLÜM 3

LİTERATÜR TARAMASI VE BULGULAR

Bu bölümde, melanom tespitinde derin öğrenme mimarilerinin kullanımını inceleyen güncel literatür çalışmaları derlenmiş olup, elde edilen bulgular karşılaştırmalı olarak sunulmuştur. İncelenen çalışmalar; kullanılan veri setleri, tercih edilen derin öğrenme algoritmaları, özellik çıkarım (feature extraction) yöntemleri ve doğruluk (accuracy) gibi temel performans metrikleri üzerinden değerlendirilmiştir. Literatür taramasından elde edilen verilerin özeti Çizelge 3.1'de verilmiş olup, ilgili çalışmaların detaylı bulguları aşağıda tartışılmıştır.

Çizelge 3.1. İncelenen literatür çalışmalarının karşılaştırmalı öz

Makale adı	Kullanılan Veri Seti	Kullanılan Model / Mimari	Train	Test	Val	Accuracy	Loss	F1 - Score	AUC	Recall	Precision
Atomali Malignant and Benign Skin Cancer Classi fication Using a Hybrid Deep Learning Approach	ISIC 2019	Resnet50	70	15	15	StackingCV: 81.6	-	0.788	0.818	0.821	-
						SVM: 81.8		0.787	0.817	0.816	
						Regression: 80.6		0.762	0.798	0.752	
						Kneighbors: 79.5		0.754	0.790	0.761	
						AdaBoost: 82.1		**0.792**	**0.822**	**0.825**	
						RF: 78.7		0.735	0.777	0.715	
						Decision Tree: 73.8		0.666	0.722	0.633	
						GaussianNB: 65.5		0.363	0.593	0.238	
		Xception				**StackingCV: 90.9**		**0.896**	**0.917**	**0.886**	
						SVM: 86.7		0.838	0.862	0.834	
						Regression: 86.3		0.837	0.862	0.853	
						Kneighbors: 79.5		0.732	0.778	0.678	
						AdaBoost: 83.7		0.801	0.831	0.798	
						RF: 80.3		0.739	0.784	0.678	
						Decision Tree: 75.7		0.676	0.736	0.614	
						GaussianNB: 76.1		0.731	0.765	0.788	
		VGG16				StackingCV (Proposed): 86.5		0.842	0.843	0.804	
								0.835	0.859	0.810	
						SVM: 86.7		**0.847**	**0.870**	**0.844**	
						Regression: 87.5		0.761	0.799	0.733	
						Kneighbors: 81		0.766	0.799	0.798	
						AdaBoost: 79.9		0.805	0.834	0.798	
						RF: 84		0.701	0.749	0.678	
						Decision Tree: 76.1		0.723	0.766	0.706	
						GaussianNB: 77.6					
		Vgg-19				91.68		91.71	98.14	90.57	92.23
		MobileNet				92.51		92.17	98.75	91.40	92.95
		ResNet-152				89.32		89.27	98.74	88.21	90.73
		EfficientNet-B0				89.46		89.31	98.43	88.21	90.21
		Inception-V3				91.82		91.76	99.06	91.12	92.28
		DSCC_Net + Smote Tomek				**94.17**		**93.93**	**99.43**	**93.76**	**94.28**

Makale adı	Kullanılan Veri Seti	Kullanılan Model / Mimari	Train	Test	Val	Accuracy	Loss	F1 - Score	AUC	Recall	Precision
Convolutional Neural Network Based Skin Lesion Analysis for Classifying Melanoma	**ISIC 2018**	**CNN**	**85**	**15**	**-**	79.42					
		VGG (Transfer learning)				**91.07**					
Deep Learning Based Skin Lesion Segmentation and Classification of Melanoma Using Support Vector Machine (SVM)	ISBI 2016	U-Net (+ LBP, HOG, Gabor ile feature extraction)	90	10	-	RF: 82.22	-	45.12	-	48.26	42.37
						SVM: 85.19		**46**		**50**	42.59
						KNN: 79.26		45.92		47.55	45.04
						NB: 65.93		44.4		43.86	**45.62**

Deep Learning–Based Methods for Automatic Diagnosis of Skin Lesions	PH2	Karar Füzyonu (Decision Fusion) - Özel NN, GoogleNet, ResNet-101, NasNet-Large ve SVM (HOG) Birleşimi	70	30	-	**Global Füzyon: 95.0** Özel NN: 93.33 SVM (HOG): 93.33 GoogleNet: 90.0 ResNet-101: 90.0 NasNet-Large: 90.0	-	-	-	-	-
	ISIC 2019					**Global Füzyon: 93.0** Özel NN: 88.33 SVM (HOG): 90.0 GoogleNet: 91.66 ResNet-101: 88.33 NasNet-Large: 88.66					
DSCC_Net: Multi-Classification Deep Learning Models for Diagnosing of Skin Cancer Using Dermoscopic Images	ISIC 2020 HAM10000 DermIS	Vgg-16	-	-	-	91.12	91.13	99.02	90.43	92.09
		Vgg-19				91.68	91.71	98.14	90.57	92.23
		MobileNet				92.51	92.17	98.75	91.40	92.95
		ResNet-152				89.32	89.27	98.74	88.21	90.73
		EfficientNet-B0				89.46	89.31	98.43	88.21	90.21
		Inception-V3				91.82	91.76	99.06	91.12	92.28
		DSCC_Net + Smote Tomek				**94.17**	**93.93**	**99.43**	**93.76**	**94.28**

3.1. Literatür Bulgularının Değerlendirilmesi

Literatürdeki çalışmalar incelendiğinde, araştırmacıların sıfırdan model eğitmek yerine genellikle önceden eğitilmiş ağları kullanarak Transfer Öğrenme (Transfer Learning) yöntemine başvurdukları görülmektedir. Örneğin, ISIC 2018 veri seti üzerinde yapılan bir çalışmada, özel tasarlanmış standart bir CNN modeli %79,42 doğruluk oranında kalırken; aynı veriler önceden eğitilmiş VGG16 mimarisine verildiğinde başarının %91,07'ye çıktığı yani başarının (accuracy) %11,65 artığı gözlemlenmiştir (Guha & Haque, 2019). Bu sayede, Transfer Öğrenme yöntemi ile eğitilmiş VGG gibi derin ağların cilt lezyonlarındaki ince detayları yakalamada geleneksel CNN mimarilerine göre çok daha yetkin olduğu görülmüştür.

Son yıllarda öne çıkan bir diğer önemli yaklaşım ise Derin Öğrenme ve Makine Öğrenmesi algoritmalarının birlikte kullanıldığı melez (hybrid) sistemlerdir. ISBI 2016 veri setini kullanan bir çalışmada, görüntüler önce U-Net mimarisi ile segmente edilmiş, ardından elde edilen özellikler Destek Vektör Makineleri (Support Vector Machine - SVM) ve Rastgele Orman (Random Forest - RF) gibi klasik sınıflandırıcılara (classifier) verilerek %85,19 oranında bir SVM başarısı elde edilmiştir (Seeja & Suresh, 2019). Benzer şekilde, ISIC 2019 veri seti üzerinde yapılan başka bir araştırmada; ResNet50, VGG16 ve Xception mimarilerinden elde edilen özellikler "Stacked CV" istifleme yöntemiyle birleştirilmiş ve en yüksek doğruluk oranına (%90,9) Xception tabanlı hibrit model ile ulaşılmıştır (Bassel vd., 2022).

Literatürdeki en yüksek doğruluk oranlarına ise birden fazla güçlü derin öğrenme ağının aynı anda kullanıldığı "Karar Füzyonu" (Decision Fusion) mimarileriyle ulaşılmaktadır. PH2 ve ISIC 2019 veri setleri üzerinde yapılan bir Karar Füzyonu çalışmasında; Özel NN (Neural Network), GoogleNet, ResNet-101, NasNet-Large ve SVM algoritmalarının tahminleri belirli ağırlıklarla birleştirilmiş (Global Fusion), bunun sonucunda PH2 veri setinde %95, ISIC 2019'da ise %93 gibi olağanüstü doğruluk (accuracy) oranları yakalanmıştır (El-Khatib vd., 2020). Literatürdeki en dikkat çekici çalışmalardan bir diğeri ise DSCC_Net adı verilen melez modelin geliştirildiği araştırmadır. Bu çalışmada araştırmacılar ISIC 2020, HAM10000 ve DermIS veri

setlerini bir araya getirerek çok sınıflı bir cilt kanseri teşhis sistemi kurmuşlardır. Modelin tasarım sürecinde VGG, MobileNet, ResNet, EfficientNet ve Inception gibi güncel mimariler birbiriyle kıyaslanmıştır. Veri setlerindeki sınıf dengesizliği problemini de SMOTE tekniğiyle aşan DSCC_Net modeli, %94,17 gibi oldukça yüksek bir doğruluk oranı yakalayarak literatürdeki en başarılı sistemlerden biri olmayı başarmıştır (Tahir vd., 2023).

BÖLÜM 4
SONUÇ

Bu çalışmada, cilt kanseri vakaları arasında en yüksek ölüm riskini taşıyan melanomun erken teşhisinde derin öğrenme algoritmalarının sunduğu çözümler ve literatürdeki güncel yaklaşımlar incelenmiştir. Yapılan literatür taraması ve incelenen bulgular, bilgisayar destekli tanı (CAD) sistemlerinin, dermatologların klinik kararlarını desteklemede kritik bir role sahip olduğunu açıkça belirtmektedir.

Literatürdeki bulgular incelendiğinde, modelleri sıfırdan eğitmek yerine Transfer Öğrenme (Transfer Learning) yaklaşımının çok daha etkili sonuçlar verdiği görülmektedir. VGG, ResNet, EfficientNet ve Inception gibi; devasa veri setlerinde önceden eğitilmiş güçlü mimariler cilt kanseri teşhisine uyarlandığında hem zaman maliyeti düşmekte hem de teşhis başarısı ciddi oranda artmaktadır. Benzer şekilde, lezyon sınırlarını hassas biçimde ayırmak için U-Net mimarisinden faydalanan veya derin ağların özellik çıkarım gücünü Destek Vektör Makineleri (SVM) ile birleştiren melez (hybrid) sistemler, sınıflandırma performansını klasik evrişimsel sinir ağlarının çok ötesine taşımaktadır.

Çalışmadan elde edilen en belirgin sonuç, tek bir derin öğrenme modeli kullanmak yerine Karar Füzyonu (Decision Fusion) mimarilerinden faydalanmanın çok daha yüksek bir teşhis başarısı sağladığıdır. GoogleNet, ResNet ve NasNet gibi farklı ağların tahmin yeteneklerini belirli ağırlıklarla harmanlayan bu sistemler, karmaşık veri setlerinde bile %95 gibi oldukça yüksek doğruluk oranları yakalayarak literatürde öne çıkmaktadır. İlerleyen süreçte veri setlerindeki sınıf dengesizliği probleminin çözülmesi ve geliştirilen bu güçlü modellerin gerçek zamanlı klinik uygulamalara entegre edilmesi, melanomun erken teşhisinde hekimlere çok daha güvenilir bir destek sunacaktır.

KAYNAKLAR

Bassel, A., Abdulkareem, A. B., Alyasseri, Z. A. A., Sani, N. S., & Mohammed, H. J. (2022). Automatic Malignant and Benign Skin Cancer Classification Using a Hybrid Deep Learning Approach. *Diagnostics (Basel, Switzerland)*, *12*(10). https://doi.org/10.3390/DIAGNOSTICS12102472

Bengio, Y., Simard, P., & Frasconi, P. (1994, Mart 2). *Learning Long-Term Dependencies with Gradient Descent is Difficult* . IEEE Transactions on Neural Networks. https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=279181

Chen, L., Bo, K., Lee, F., & Chen, Q. (2020). Advanced feature fusion algorithm based on multiple convolutional neural network for scene recognition. *CMES - Computer Modeling in Engineering and Sciences*, *122*(2), 505-523. https://doi.org/10.32604/CMES.2020.08425

Chollet, F. (2016). Xception: Deep Learning with Depthwise Separable Convolutions. *Proceedings - 30th IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2017*, *2017-January*, 1800-1807. https://doi.org/10.1109/CVPR.2017.195

Demirtaş, O., Kuş, S., Demirel, S., Akkaya, H. E., Yıldız, O., & Kazcı, Ö. (2025). Deep Learning–Based Diagnosis of Chondromalacia Patella from Magnetic Resonance Images. *Current Research in MRI*, *4*(1), 12-21. https://doi.org/10.5152/CURRRESMRI.2025.25118

DermIS. (2026). https://www.dermis.net/dermisroot/tr/home/index.htm

El-Khatib, H., Popescu, D., & Ichim, L. (2020). Deep learning–based methods for automatic diagnosis of skin lesions. *Sensors (Switzerland)*, *20*(6). https://doi.org/10.3390/S20061753

Gezer, A., Tolga YILMAZ, M., & Özdemir, D. (2024). *VGG16'da Araç Hasar Tespiti*. https://doi.org/10.53608/estudambilisim.1421332

Guha, S. R., & Haque, S. M. R. (2019). Convolutional neural network based skin lesion analysis for classifying melanoma. *2019 International Conference on Sustainable Technologies for Industry 4.0, STI 2019*. https://doi.org/10.1109/STI47673.2019.9067979

Guo, Y., Cao, X., Liu, B., & Gao, M. (2020). Cloud detection for satellite imagery using attention-based U-net convolutional neural network. *Symmetry*, *12*(6). https://doi.org/10.3390/SYM12061056

Gutman, D., F Codella, N. C., Celebi, E., Helba, B., Marchetti, M., Mishra, N., & Halpern, A. (2016). *Skin Lesion Analysis toward Melanoma Detection: A Challenge at the International Symposium on Biomedical Imaging (ISBI) 2016, hosted by the International Skin Imaging Collaboration (ISIC)*. https://isic-archive.com/

Haenssle, H. A., Fink, C., Schneiderbauer, R., Toberer, F., Buhl, T., Blum, A., Kalloo, A., Ben Hadj Hassen, A., Thomas, L., Enk, A., Uhlmann, L., Alt, C., Arenbergerova, M., Bakos, R., Baltzer, A., Bertlich, I., Blum, A., Bokor-Billmann, T., Bowling, J., … Zalaudek, I. (2018). Man against Machine: Diagnostic performance of a deep learning convolutional neural network for dermoscopic melanoma recognition in comparison to 58 dermatologists. *Annals of Oncology*, *29*(8), 1836-1842. https://doi.org/10.1093/annonc/mdy166

He, K., Zhang, X., Ren, S., & Sun, J. (2015). *Deep Residual Learning for Image Recognition*. http://image-net.org/challenges/LSVRC/2015/

Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., & Andreetto, M. (2017). *MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications*.

Jones, O. T., Jurascheck, L. C., Van Melle, M. A., Hickman, S., Burrows, N. P., Hall, P. N., Emery, J., & Walter, F. M. (2019). Dermoscopy for melanoma detection and triage in primary care: a systematic review. *BMJ open*, *9*(8). https://doi.org/10.1136/bmjopen-2018-027529

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2017). ImageNet classification with deep convolutional neural networks. *Communications of the ACM*, *60*(6), 84-90. https://doi.org/10.1145/3065386

LeCun, Y. A., Bottou, L., Orr, G. B., & Müller, K. R. (2012). Efficient BackProp. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, *7700 LECTURE NO*, 9-48. https://doi.org/10.1007/978-3-642-35289-8_3

Mendonca, T., Ferreira, P. M., Marques, J. S., Marcal, A. R. S., & Rozeira, J. (2013). PH2 - A dermoscopic image database for research and benchmarking. *Proceedings of the Annual International Conference of the IEEE Engineering in Medicine and Biology Society, EMBS*, 5437-5440. https://doi.org/10.1109/EMBC.2013.6610779

Nair, V., & Hinton, G. E. (2010). *Rectified Linear Units Improve Restricted Boltzmann Machines*.

Naseri, H., & Safaei, A. A. (2025). Diagnosis and prognosis of melanoma from dermoscopy images using machine learning and deep learning: a systematic literature review. *BMC cancer*, *25*(1). https://doi.org/10.1186/s12885-024-13423-y

Neris, R., Rodriguez, A., Guerra, R., Lopez, S., & Sarmiento, R. (2022). FPGA-Based Implementation of a CNN Architecture for the On-Board Processing of Very High-Resolution Remote Sensing Images. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, *15*, 3740-3750. https://doi.org/10.1109/JSTARS.2022.3169330

Öztürk, E., & Mesut, A. (2020). DERİN ÖĞRENME KULLANILARAK OPTİMUM JPEG KALİTE FAKTÖRÜNÜN BELİRLENMESİ. *Mühendislik Bilimleri ve Tasarım Dergisi*, *8*(4), 1010-1018. https://doi.org/10.21923/jesd.698719

Pal, A., Kar, S., Taneja, A., & Jadoun, V. K. (2020). Image Captioning and Comparison of Different Encoders. *Journal of Physics: Conference Series*, *1478*(1). https://doi.org/10.1088/1742-6596/1478/1/012004

Phung, V. H., & Rhee, E. J. (2019). A High-accuracy model average ensemble of convolutional neural networks for classification of cloud image patches on small datasets. *Applied Sciences (Switzerland)*, *9*(21). https://doi.org/10.3390/APP9214500

Ronneberger, O., Fischer, P., & Brox, T. (2015). *U-Net: Convolutional Networks for Biomedical Image Segmentation*. http://lmb.informatik.uni-freiburg.de/

Seeja, R. D., & Suresh, A. (2019). Deep Learning Based Skin Lesion Segmentation and Classification of Melanoma Using Support Vector Machine (SVM). *Asian Pacific Journal of Cancer Prevention : APJCP*, *20*(5), 1555. https://doi.org/10.31557/APJCP.2019.20.5.1555

Sharifani, K., & Amini, M. (2023). Machine Learning and Deep Learning: A Review of Methods and Applications. *World Information Technology and Engineering Journal*, *10*. https://ssrn.com/abstract=4458723

Simonyan, K., & Zisserman, A. (2015). *VERY DEEP CONVOLUTIONAL NETWORKS FOR LARGE-SCALE IMAGE RECOGNITION*. http://www.robots.ox.ac.uk/

Srinivasan, K., Garg, L., Datta, D., Alaboudi, A. A., Jhanjhi, N. Z., Agarwal, R., & Thomas, A. G. (2021). Performance comparison of deep cnn models for detecting driver's distraction. *Computers, Materials and Continua*, *68*(3), 4109-4124. https://doi.org/10.32604/CMC.2021.016736

Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., Erhan, D., Vanhoucke, V., & Rabinovich, A. (2014). Going Deeper with Convolutions. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, *07-12-June-2015*, 1-9. https://doi.org/10.1109/CVPR.2015.7298594

Tahir, M., Naeem, A., Malik, H., Tanveer, J., Naqvi, R. A., & Lee, S. W. (2023). DSCC_Net: Multi-Classification Deep Learning Models for Diagnosing of Skin Cancer Using Dermoscopic Images. *Cancers 2023, Vol. 15, Page 2179*, *15*(7), 2179. https://doi.org/10.3390/CANCERS15072179

Tan, M., & Le, Q. V. (2019). *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*.

Türk Kanser Derneği. (2026). *Cilt Kanseri Belirtileri, Türleri ve Erken Teşhis Yolları*. https://turkkanserdernegi.org/kanser-hakkinda/cilt-kanseri

Zhou, A., Ma, Y., Ji, W., Zong, M., Yang, P., Wu, M., & Liu, M. (2023). Multi-head attention-based two-stream EfficientNet for action recognition. *Multimedia Systems*, *29*(2), 487-498. https://doi.org/10.1007/S00530-022-00961-3

Zoph, B., Brain, G., Vasudevan, V., Shlens, J., & Le Google Brain, Q. V. (2018). *Learning Transferable Architectures for Scalable Image Recognition*.

ÖZGEÇMİŞ

Moustafa Moustafa, 2003 yılında Yunanistan Gümülcine'de doğdu. Lisans eğitimini Trakya Üniversitesi Mühendislik Fakültesi Bilgisayar Mühendisliği Bölümü'nde tamamladı. 2025 yılında mezun olduktan sonra Trakya Üniversitesi Fen Bilimleri Enstitüsü Bilgisayar Mühendisliği Anabilim Dalı'nda yüksek lisans eğitimine başladı ve eğitimine devam etmektedir. Lisans ve yüksek lisans eğitimi süresince yapay zekâ, makine öğrenmesi, görüntü işleme alanlarında çalışmalar yapmıştır.